# Universidad de los Andes Colombia Universidad de los Institucion de alta calid 10 año Colombia

# Ingeniería de Sistemas y Computación

Pregrado
ISIS-3301 – Inteligencia de Negocios
Primer Proyecto

Primer Proyecto Semestre: 2025-20



# Proyecto 1. Analítica de textos

## Contenido

I.	Descripción general Fondo de Poblaciones de las Naciones Unidas	. 1
II.	Entregas	. 1
III.	Actividades	. 2
IV.	Etapa 1. Construcción de modelos de analítica de textos	. 3
V.	Etapa 2. Automatización y uso de modelos de analítica de textos	12
VI.	Condiciones de las entregas ¡Error! Marcador no definid	lo.

# I. Descripción general Fondo de Poblaciones de las Naciones Unidas.

El 25 de septiembre de 2015, la Organización de las Naciones Unidas (ONU) adoptó la Agenda 2030 para el Desarrollo Sostenible, con el objetivo de erradicar la pobreza, garantizar el acceso a la salud y la educación, promover la igualdad de género y reducir el impacto ambiental, entre otras metas. Para ello, se establecieron 17 Objetivos de Desarrollo Sostenible (ODS)<sup>1</sup> y 169 metas asociadas. En este marco, diversas entidades, como el Fondo de Población de las Naciones Unidas (UNFPA)2, participan en el seguimiento y evaluación de políticas públicas, utilizando herramientas de participación ciudadana para identificar problemáticas y evaluar soluciones en función de los ODS.

Uno de los mayores desafíos en este proceso es el análisis de información textual proveniente de distintas fuentes vinculadas a la planificación participativa territorial. Esta tarea demanda recursos significativos y expertos capaces de relacionar los contenidos con los ODS. Contar con este conocimiento permitiría tomar decisiones más informadas basadas en la opinión ciudadana, orientando las políticas públicas hacia el cumplimiento de la Agenda 2030.

El UNFPA busca desarrollar un proyecto conjunto con ustedes, cuyo objetivo principal es vincular de forma automática las opiniones de la ciudadanía con los Objetivos de Desarrollo Sostenible (ODS) 1, 3 y 4. Para ello, se deberá aplicar una metodología de desarrollo de

<sup>&</sup>lt;sup>1</sup> https://www.un.org/sustainabledevelopment/es/objetivos-de-desarrollo-sostenible/

<sup>&</sup>lt;sup>2</sup> https://colombia.unfpa.org/es/unfpa-en-colombia



Pregrado

ISIS-3301 – Inteligencia de Negocios

Primer Proyecto Semestre: 2025-20



aplicaciones analíticas que permita crear un modelo capaz de analizar y clasificar dichas opiniones. Este modelo deberá integrarse en una aplicación web o móvil, desde la cual podrá ser utilizado y reentrenado continuamente a partir de textos en lenguaje natural.

# II. Entregas.

El desarrollo de este proyecto se realizará en dos etapas:

Etapa 1. Construcción de modelos de analítica de textos, donde el rol principal es el de un científico de datos. El trabajo se centra en la construcción de modelos analíticos sin dejar de lado el entendimiento del negocio, los datos y por supuesto, la evaluación y utilidad de los resultados obtenidos con el modelo seleccionado. Fecha máxima de entrega 13 de septiembre 20:00.

**Etapa 2**. Ajuste, automatización y uso de modelos de analítica de textos. Continuando con el rol de científico de datos, esta etapa comienza con el ajuste del modelo mediante una estrategia de aumentación de datos basada en *prompting*, orientada a reforzar la representación de la clase minoritaria para mejorar el desempeño del modelo en escenarios con desbalance de clases. Posteriormente, siguiendo un rol de ingeniero de datos, realizar el despliegue y automatización del modelo en una aplicación para el usuario final, asegurando que la solución funcione correctamente con nuevos datos y en diferentes momentos del tiempo. **Fecha máxima de entrega 11 de octubre 20:00.** 

Si la entrega o la fecha de los entregables está después de las 20:00 y hasta las 2:00 am del siguiente día, tendrá una penalización del 30% y su entrega se califica sobre 3.5. Cualquier entrega posterior a las 2:00 a.m. por otros canales tendrá una nota de 0.

## III. Actividades.

Cada grupo participante debe realizar los siguientes pasos, antes de iniciar el desarrollo del proyecto:

- **a.** Conformar su grupo de mínimo 2 y máximo 3 estudiantes. Recuerde que los grupos de proyecto pueden involucrar estudiantes de distintas secciones y pueden ser diferentes a los grupos de los laboratorios.
- **b. Registrar el grupo** en BloqueNeón. Deben registrar su grupo en BloqueNeón para habilitar el enlace de entrega del proyecto.



Pregrado
ISIS-3301 – Inteligencia de Negocios

Primer Proyecto Semestre: 2025-20



#### c. Leer todo este documento

# IV. Etapa 1. Construcción de modelos de analítica de textos

#### **Objetivo**

• Aplicar la metodología de analítica de textos para la construcción de soluciones de analítica alineadas con los objetivos de organizaciones en un contexto de aplicación.

#### Descripción de la etapa 1

En esta etapa será científico de datos. El científico de datos tiene la responsabilidad de seguir un proceso replicable y de calidad, para entender los datos, prepararlos, construir el modelo analítico y evaluarlo, tanto a nivel cuantitativo como cualitativo. En este caso, cada grupo debe trabajar con opiniones que representan la voz de los habitantes locales para identificar las problemáticas de su entorno en términos de los ODS 1, 3 y 4, relacionados con "Fin de la pobreza", "Salud y bienestar" y "Educación de calidad". En esa tarea se requiere construir un modelo analítico que permita relacionar de forma automática nuevas opiniones, al igual que analizar las palabras que llevan a relacionar una opinión con un ODS.

#### Descripción de los entregables

A continuación, se presentan las secciones que debe incluir el documento y los diferentes entregables a realizar y espacios de evaluación.

## Sección 1. (20%) Documentación del proceso de aprendizaje automático.

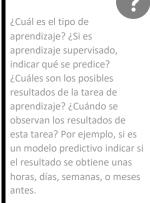
Complete el siguiente Canvas de aprendizaje automático. Adaptación de *OWNML MACHINE LEARNING CANVAS*. [CRISP-ML(Q). The ML Lifecycle Process]



Acreditación institución ISIS-3301 – Inteligencia de Negocios de alta calia 10 año Primer Proyecto
Mineducción de servición Semestre: 2025-20



## TAREA DE APRENDIZAJE





#### **DECISIONES**

¿Cómo se convierten los resultados del modelo en recomendaciones o decisiones procesables para el usuario final?



## PROPUESTA DE VALOR

¿Quién es el beneficiario final? ¿De qué empresa es? ¿Qué problemas específicos se abordan? ¿Qué riesgo puede tener para ese beneficiario el uso de este modelo?



# RECOLECCIÓN DE DATOS — NO SE DEBE

**DILIGENCIAR** 

¿Cómo se obtiene el conjunto inicial de entidades y resultados (por ejemplo, extractos de bases de datos, extracciones de API, etiquetado manual)? ¿Qué estrategias se aplican para actualizar los datos continuamente, controlando los costos y manteniendo



¿Qué fuentes de datos se utilizan? (Mencione tablas de bases de datos internas y externas o métodos API). ¿De dónde se toman los datos? ¿Se pueden utilizar para realizar el objetivo del análisis?

#### SIMULACIÓN DE IMPACTO

¿Cuáles son los valores de costo/beneficio de las decisiones (in)correctas? ¿Cuáles son los criterios de éxito del modelo para su posterior despliegue? ¿Existen restricciones de equidad?



# APRENDIZAJE (USO DEL MODELO)

¿El uso del modelo es por lotes o en tiempo real? ¿Con qué frecuencia se usa?



DE MODELOS

¿Cuántos modelos se necesitan? ¿Cuándo deben actualizarse? ¿De cuánto tiempo se dispone para generar el modelo (incluido el proceso de ingeniería de características y el análisis o evaluación del mismo)?



¿Qué variables/características se utilizan en el modelo? ¿Qué agregaciones o transformaciones se aplican a las fuentes de datos originales – incluir las más importantes--?



Pregrado

ISIS-3301 – Inteligencia de Negocios

10 año
Mineducaci
Primer Proyecto
Semestre: 2025-20







Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a <u>Creative Commons Attribution-ShareAlike 4.0 International License</u>. Please keep this mention and the link to <u>ownml.co</u> when sharing.

Sección 2. (20%) Entendimiento y preparación de los datos. Perfilamiento y análisis de la calidad de los datos. Además, deben incluir el tratamiento de los datos (preparación o transformaciones requeridas), de acuerdo con el dominio, las técnicas y los algoritmos seleccionados para resolver el problema planteado.

Sección 3. (20%) Modelado y evaluación. Aplicación de mínimo tres algoritmos diferentes para la tarea de aprendizaje automático seleccionada. Es posible utilizar algoritmos no vistos en clase. En esta parte deben describir los algoritmos utilizados para la construcción de los modelos y presentar los resultados de las métricas de evaluación para justificar la selección del modelo. Además, deben incluir los nombres de los estudiantes que trabajaron en cada modelo analítico.

Cada estudiante del grupo debe realizar al menos uno de esos algoritmos. La nota obtenida en esta sección se utiliza para asignar parte de la nota individual de la entrega.

Sección 4. (20%) Resultados.

# Universidad de institucion de alta calid 10 año los Andes

## Ingeniería de Sistemas y Computación

Pregrado ISIS-3301 - Inteligencia de Negocios **Primer Proyecto** 

Semestre: 2025-20



- a. Descripción de los resultados obtenidos, que permita a la organización comprenderlos, haciendo énfasis en el análisis de las métricas de calidad arrojadas por los modelos utilizados y cómo aportan en la consecución de los objetivos del negocio.
- b. Incluir el análisis de las palabras identificadas para relacionar las opiniones con los ODS y posibles estrategias que la organización debe plantear utilizando los resultados obtenidos en los modelos analíticos y una justificación de por qué esa información es útil para ellos.
- c. Entregar los datos de prueba compartidos, en formato excel, con una columna adicional que contiene la etiqueta asignada por el modelo que seleccionaron. Este archivo se utiliza para determinar el f1-score de su modelo analítico y compararlo con los de los diferentes grupos para asignar parte de la nota del grupo.
- d. Generar un video de máximo 5 minutos explicando su proyecto y resultados. El video debe estar en la wiki respectiva..

Importante: justifiquen cada decisión tomada en cada una de las fases.

#### Sección 5. (8%) Trabajo en equipo

- Describir los roles y las tareas realizadas por cada integrante del grupo (ver sugerencias en la siguiente viñeta), los tiempos, en número de horas, dedicados para realizar lo que le fue asignado, el algoritmo trabajado, los retos enfrentados en el proyecto, las formas planteadas para resolverlos y el uso que le dieron a ChatGPT en este proceso.
- Reportar la forma como distribuyen 100 puntos entre los integrantes del grupo e identificar puntos a mejorar para la siguiente entrega del proyecto. Tenga en cuenta el compromiso en el logro de resultados, la calidad de la contribución, el cumplimiento de compromisos adquiridos con el grupo y la participación equitativa en el trabajo del grupo.
- A nivel del trabajo en equipo se sugieren los siguientes roles para cada integrante. Un integrante puede desempeñar más de un rol.
  - o Líder de proyecto: Está a cargo de la gestión del proyecto. Define las fechas de reuniones, pre-entregables del grupo y verifica las asignaciones de tareas para que la carga sea equitativa. Se encarga de subir la entrega del grupo. Si no hay consenso sobre algunas decisiones, tiene la última palabra.

# Universidad de los Andes 10 año

## Ingeniería de Sistemas y Computación

Pregrado ISIS-3301 - Inteligencia de Negocios **Primer Proyecto** 

Semestre: 2025-20



- o Líder de negocio: Es responsable de velar por resolver el problema o la oportunidad identificada y estar alineado con la estrategia del negocio para el cual se plantea el proyecto. Debe garantizar que el producto se puede comunicar de forma apropiada.
- Líder de datos: Se encarga de gestionar los datos que se van a usar en el proyecto y de las asignaciones de tareas sobre datos. Debe dejarlos disponibles para todo el grupo y garantizar la entrega en el repositorio de git.
- o Líder de analítica: Se encarga de gestionar las tareas de analítica del grupo. Se encarga de verificar que los entregables cumplen con los estándares de análisis y que se tiene el "mejor modelo" según las restricciones existentes.
- Se recomiendan al menos las siguientes reuniones de grupo:
  - o Reunión de lanzamiento y planeación: Para definir roles y forma de trabajo del grupo. Se genera lluvia de ideas sobre la forma de resolver el proyecto.
  - o Reunión de ideación: Una vez se han explorado los datos del proyecto, la reunión de ideación busca definir la organización/empresa/institución y el rol dentro de ella, que se beneficia de la solución analítica que van a desarrollar.
  - o Reuniones de seguimiento: Se recomienda mínimo una reunión de seguimiento semanal corta. También pueden ser correos de avance según lo defina el grupo.
  - o **Reunión de finalización**: Para consolidar el trabajo final, verificar el trabajo del grupo y analizar los puntos a mejorar para la siguiente etapa del proyecto.

#### Otros entregables y espacios de evaluación

- a. (12%) Sustentación y evaluación del aporte individual. Se revisa lo entregado y se valida el aporte individual y la concordancia entre el documento y la sustentación.
- b. Conjunto de datos resultado de la fase de entendimiento y preparación de los datos. Requerido para realizar la sustentación.
- c. Repositorio: Se debe crear un repositorio para el proyecto del curso, en el cual debe crear una wiki para incluir los diferentes entregables. Debe almacenar el código de la solución creada y referenciarlo en los entregables. Puede acceder a beneficios de estudiante en https://education.github.com/pack. El entregable en BloqueNeón es la dirección de la wiki (dentro del repositorio), donde registró todo lo solicitado en esta



Pregrado
ISIS-3301 – Inteligencia de Negocios
Primer Proyecto
Semestre: 2025-20



etapa del proyecto. El github de su proyecto puede ser un repositorio público o compartido a través de githubfront para garantizar que los monitores tengan acceso.

#### Bono

Los grupos que obtengan los mejores cinco resultados de acuerdo con las métricas de desempeño de los modelos propuestos (0.3/5.0)

V. Etapa 2. Ajuste, automatización y uso de modelos de analítica de textos.

## **Objetivos**

- Implementar un proceso de reentrenamiento de modelos con datos aumentados mediante prompting, con el objetivo de mejorar su rendimiento, robustez y capacidad de generalización
- Automatizar un proceso replicable para aplicar la metodología de analítica de textos en la construcción de modelos analíticos.
- Desarrollar una aplicación que utilice un modelo analítico basado en aprendizaje automático y sea de interés para una organización, empresa o institución y en particular para un rol existente en alguna de ellas.

#### Descripción de la etapa 2

Esta etapa tiene dos objetivos. El primero, continuando con el rol de científico de datos, se centra en el reentrenamiento del modelo utilizando aumentación de datos mediante estrategias de *prompting*. El segundo, está relacionado con las actividades que realiza el ingeniero de datos para el despliegue de los modelos, acompañado del ingeniero de software. El ingeniero de datos tiene la responsabilidad de tomar el resultado entregado por el científico de datos, completarlo incluyendo elementos como pruebas, organización de código, validación de atributos de calidad (e.g., eficiencia), además de persistir el modelo generado en un repositorio específico para este fin. Adicionalmente, deben extender el código para incluir el registro o log, que permita en caso de falla, revisar las entradas al modelo, los datos utilizados para el entrenamiento y prueba del modelo y el resultado de la preparación. El ingeniero de software toma ese resultado como entrada de la aplicación



Pregrado
ISIS-3301 – Inteligencia de Negocios
Primer Proyecto

Primer Proyecto Semestre: 2025-20



web o móvil que debe diseñar y construir, la cual es utilizada por el usuario final para ingresar su solicitud al modelo, interactuar con el resultado y apoyar sus acciones o decisiones.

En esta etapa 2 deben reentrenar el modelo con los datos aumentados y comparar su rendimiento con el modelo creado en la etapa 1, así como desarrollar una aplicación orientada a un usuario con sentido y apoyo a cualquier acción o decisión de este.

Recuerden registrar el grupo en BloqueNeón en la categoría "Grupos proy1 Etapa 2" para tener acceso al enlace de entrega.

#### Descripción de la entrega

A continuación, se presentan las secciones que debe incluir el documento y los diferentes entregables a realizar y espacios de evaluación.

Sección 1. (10%) Aumentación de datos y reentrenamiento del modelo. Aplicación de técnicas de *prompting* para aumentación de la clase minoritaria. Se debe construir un modelo con los nuevos datos utilizando el algoritmo que haya reportado los mejores rendimientos en la etapa 1. Además, construir una tabla comparativa que muestre los valores de las métricas de evaluación sobre test, de los dos modelos.

Sección 2. (15%) Proceso de automatización del proceso de preparación de datos, construcción del modelo, persistencia del modelo y acceso por medio de API: Descripción del proceso e implementación realizados por el ingeniero de datos, acompañado del código. Debe utilizar *pipelines* para este proceso y un Framework para desarrollo de la API. La API REST debe estar compuesta por dos "endpoints":

 El primero debe recibir mediante el "body" una o más instancias de datos con la totalidad de las características requeridas para las que se desea realizar la predicción.
 Este "endpoint" debe devolver una lista con la misma cardinalidad de las instancias recibidas, y en el mismo orden, que contenga las predicciones realizadas por el modelo para cada instancia de datos recibida.

El segundo "endpoint", debe estar en capacidad de enviar una cantidad relevante de instancias de datos que servirán para realizar un proceso de re-entrenamiento del modelo, razón por la cual, además de enviar las características, también será requisito enviar la



Pregrado ISIS-3301 – Inteligencia de Negocios

Primer Proyecto Semestre: 2025-20



variable objetivo. Como respuesta, el "endpoint" debe devolver algunas métricas de desempeño como pueden ser el Precision, Recall, F1-score. Además, tenga presente que con el proceso de re-entrenamiento del modelo, el archivo binario deberá reemplazarse para ser tenido en cuenta como nueva versión la próxima vez que se solicite realizar una predicción mediante el primer "endpoint". En este punto debe investigar y plantear tres definiciones distintas de re-entrenamiento. En cada una de ellas debe incluir una descripción del significado, acompañada de una ventaja o desventaja de esa propuesta. Al final debe concluir indicando la que implementó en esta etapa del proyecto. Los datos tanto de la solicitud como de la respuesta deben estar en formato JSON y deben respetar el esquema del CSV original proporcionado para este proyecto 1. Recuerde que el pipeline es el encargado de hacer todas las preparaciones requeridas previo a hacer los procesos de entrenamiento o predicción.

## Sección 3. (35%) Desarrollo de la aplicación y justificación.

- Descripción del usuario/rol de la organización que va a utilizar la aplicación, la conexión entre esa aplicación y el proceso de negocio que va a apoyar (si aplica), y la importancia que tiene para ese rol la existencia de esta aplicación.
- Desarrollo de una aplicación web o móvil para interactuar con el resultado del modelo analítico a partir de un texto o textos dados por el usuario. Recuerde que la interacción incluye tanto la predicción como la probabilidad asociada a la misma. A nivel de usuario experto en modelos analíticos, debe brindar la opción de re-entrenar el modelo, según la semántica que seleccionó.
- Resuelva las siguientes preguntas con respecto a la aplicación a desplegar: ¿Qué recursos informáticos requiere para entrenar, ejecutar, persistir el modelo analítico y desplegar la aplicación? ¿Cómo se integrará la aplicación construida a la organización, estará conectada con algún proceso del negocio o cómo se pondrá a disposición del usuario final? ¿Qué riesgos tiene para el usuario final usar la aplicación construida?

**Sección 4. (18%) Resultados**. Video de máximo 5 minutos con la descripción y visualización en la aplicación de los resultados del modelo analítico, que permita a un rol dentro de la organización comprenderlos y usarlos. El video debe simular la interacción del usuario final con la aplicación y describir dos acciones que puede realizar como resultado de dicha interacción, haciendo énfasis en la forma como el resultado del modelo aporta en esas



Pregrado
ISIS-3301 – Inteligencia de Negocios
Primos Provocto

Primer Proyecto Semestre: 2025-20



acciones y reflexionando sobre el posible impacto a nivel Colombia el uso de la aplicación desarrollada.

Realice pruebas de facilidad de uso de la aplicación y utilidad para el usuario para el cual se diseñó, puede vincular a otros estudiantes del curso o personas cercanas para esta validación.

## Sección 5. (10%) Trabajo en equipo.

- Describir los roles y las tareas realizadas por cada integrante del grupo (ver sugerencias en la siguiente viñeta), los tiempos, en número de horas, dedicados para realizar lo que le fue asignado, al igual que el algoritmo trabajado, los retos enfrentados en el proyecto y las formas planteadas para resolverlos.
- Reportar la forma como distribuyen 100 puntos entre los integrantes del grupo e identificar puntos a mejorar para la siguiente entrega del proyecto. Tenga en cuenta el compromiso en el logro de resultados, la calidad de la contribución, el cumplimiento de compromisos adquiridos con el grupo y la participación equitativa en el trabajo del grupo.
- A nivel del trabajo en equipo se sugieren los siguientes roles para cada integrante. Un integrante puede desempeñar más de un rol.
  - Líder de proyecto: Está a cargo de la gestión del proyecto. Define las fechas de reuniones, pre-entregables del grupo y verifica las asignaciones de tareas para que la carga sea equitativa. Se encarga de subir la entrega del grupo. Si no hay consenso sobre algunas decisiones, tiene la última palabra.
  - o **Ingeniero de datos:** Es responsable de velar por la calidad del proceso de automatización relacionado con la construcción del modelo analítico.
  - Ingeniero de software responsable del diseño de la aplicación y resultados: Se encarga de liderar el diseño de la aplicación y de la generación del video con los resultados obtenidos.
  - o **Ingeniero de software responsable de desarrollar la aplicación final**: Se encarga de gestionar el proceso de construcción de la aplicación.
- Se recomiendan al menos las siguientes reuniones de grupo:
  - Reunión de lanzamiento y planeación: Para definir roles y forma de trabajo del grupo. Se genera lluvia de ideas sobre la forma de resolver el proyecto.



Pregrado
ISIS-3301 – Inteligencia de Negocios
Primer Proyecto
Semestre: 2025-20



- o **Reuniones de seguimiento**: Se recomienda mínimo dos reuniones de seguimiento semanal cortas. También pueden ser correos de avance según lo defina el grupo.
- o **Reunión de finalización**: Para consolidar el trabajo final, verificar el trabajo del grupo y analizar los puntos a mejorar para el siguiente proyecto.

#### Otros entregables

- a. (12%) Aporte individual. Con base en lo descrito en el documento se calcula este aporte.
- b. Entregar el conjunto de datos resultado de la fase de entendimiento y preparación de los datos. Requerido para realizar la sustentación.
- c. Utilizar el github de la entrega anterior para dejar el código y debe ser referenciado en los entregables. Recuerden que pueden acceder a beneficios de estudiante en <a href="https://education.github.com/pack">https://education.github.com/pack</a>.

# VI. Condiciones de entrega.

- El proyecto se realiza en grupos de 3 estudiantes. Los estudiantes pueden estar en distintas secciones.
- El documento tiene máximo 10 páginas (sin incluir portada, tabla de contenido, ni referencias), a una columna y con letra arial, tamaño 12.
- Deben indicar el uso que le dieron a la inteligencia artificial generativa en la elaboración de código o del documento relacionado con las entregas.
- El repositorio debe tener todo el código fuente de la aplicación y del modelo analítico para poder ejecutarlo durante la revisión del proyecto.